

알기쉬운 인공지능

박종욱 교수



3주차

인공지능과 윤리



학 습 목 표

1. 인공지능 윤리의 필요성을 이해할 수 있다.
2. 인공지능 윤리안을 가질 수 있다.
2. 인공지능 윤리규범 및 동향을 알 수 있다.

학 습 내 용

- | | |
|-----------------|-------------------|
| 1. 인공지능 특이점 | 4. 인공지능 윤리안 |
| 2. 인공지능 윤리의 필요성 | 5. 인공지능 윤리규범 및 동향 |
| 3. 인공지능 윤리적 딜레마 | |



3. 인공지능과 윤리

1) 인공지능 특이점의 개념

- 특이점(Singularity)

- 인공지능이 인간의 지능을 초월하는 시점으로, 사람이 기술의 발전을 따라잡을 수 없는 시기




3. 인공지능과 윤리

1) 인공지능 특이점의 개념

- 특이점(Singularity)

- 특이점에 도달하는 시대에는 컴퓨터가 자신보다 발달한 인공지능을 직접 설계 및 제작할 것이며, 그 인공지능은 자신보다 더 좋은 지능을 가진 또 다른 인공지능을 설계하고 생산할 수 있게 될 것임
- 우리가 특이점을 대비하고 준비해야 하는 이유는 인공지능에 대한 통제력과 관련이 있음



3. 인공지능과 윤리

1) 인공지능 특이점의 개념

• 반 인공지능파의 주장

- 사회적 불평등 가속화
→ AI로 대체된 일자리로 생계의 어려움
- 특이점 이후 통제 불가능성의 위험

• 친 인공지능파의 주장

- 생산의 효율성, 안전한 작업환경 구축
- 노동으로부터 해방
→ 더 가치 있는 일에 투자 가능
- 인공지능의 통제 가능성(kill switch)

생성형 AI 개발 중단 찬반 논쟁


개발 속도 조절해야	 "GPT-4보다 더 강력한 AI는 인류 위험 초래. 개발을 최소 6개월 잠정 중단하자." (미국 '삶의 미래 연구소' 공개서한) 스티브 워즈니악 애플 공동창업자, 일론 머스크 테슬라 CEO, 유발 하라리 예루살렘히브리대 교수 등
	 "기술 개발자들도 AI가 인류 실존에 위협 인정. 그러면서도 위험을 완화할 계획 없어." 에마드 모스타크 스테빌리티AI CEO
신중론	 "AI는 질병과 기후문제 해결에 도움 되지만 국가안보와 사회의 잠재적 위험 해결 역시 중요." (과학기술자문위원회 회의) 조 바이든 미국 대통령
개발 중단하면 안 돼	 "일시 중단을 요청한다고 문제가 해결 되지 않는다. 분명한 건 이 기술에 큰 이점이 있다는 것." 빌 게이츠 마이크로소프트(MS) 창업자
	 "AI 개발 중단은 말도 안 되는 일. 유익한 기술의 위험성을 꾸며서 사람들을 두렵게 하는 것." 안 르륀 메타 수석과학자
	 "AI 개발을 6개월간 유예하자는 건 꿈쩍한 아이디어" 앤드루 응 딥러닝AI 창립자



3. 인공지능과 윤리

2) 인공지능 윤리의 필요성

- 구글의 이미지 인식(Image Recognition) 사례
 - 이미지 인식 중 흑인 여성을 고릴라로 인식
- MIT 미디어랩의 발표 자료
 - 인공지능이 백인 남성 얼굴을 인식하는 과정에서 오류를 일으킬 확률은 1%
 - 흑인 여성의 경우 오류 발생 확률이 35%까지 상승
- 위챗(WeChat) 번역 과정 사례
 - 니그로(Negro)라는 단어를 사용




3. 인공지능과 윤리


3) 인공지능의 윤리적 딜레마

• 트롤리 사례

- 윤리학 분야의 사고실험 중 하나
- 다섯 사람을 구하기 위해 한 사람을 죽이는 것이 도덕적으로 허용 가능한지에 대한 질문



트롤리 사례



자율주행차의 트롤리 사례



3. 인공지능과 윤리

3) 인공지능의 윤리적 딜레마

- 사람과 자율주행차에 대한 이중잣대



3. 인공지능과 윤리

4) 인공지능 윤리안

- 아실로마 인공지능 원칙(Asilomar AI Principles)

- 인공지능 개발의 목적, 윤리, 가치 등에 대해 개발자가 지켜야 할 23가지 준칙
- 이 원칙은 연구 관련 쟁점, 윤리와 가치, 장기적 이슈 등 총 3가지 부분으로 구성

① 연구 관련 쟁점 : 연구 목표, 연구비 지원, 과학정책 연계, 연구 문화, 경쟁 회피 등

② 윤리와 가치 : 안전, 실패의 투명성, 사법적 투명성, 책임성, 가치 일치, 인간의 가치, 개인정보 보호, 자유와 프라이버시, 이익의 공유, 번영의 공유, 인간 통제, 사회전복 방지, 인공지능 무기 경쟁 지양 등

③ 장기적 이슈 : 역량 경고, 중요성, 위험성, 자기개선 순환, 공동의 선 등




3. 인공지능과 윤리


4) 인공지능 윤리안

- 로봇 3원칙(The Three Laws of Robotics)

- 로봇이 반드시 따라야 할 3가지 원칙
- 로봇 3원칙을 제시한 작가 아이작 아시모프(Isaac Asimov)는 이 원칙들만 잘 지킨다면 로봇이 인간에게 위협이 될 일은 없을 것이라고 생각함



제1원칙 로봇은 인간에게 해를 입혀서는 안 되고, 위험에 처한 인간을 방치해서도 안 된다.



제2원칙 제1원칙을 어기지 않는 한, 로봇은 인간의 명령에 복종해야 한다.



제3원칙 제1원칙과 제2원칙을 어기지 않는 한, 로봇은 로봇 자신을 지켜야 한다.




3. 인공지능과 윤리

5) 인공지능 윤리규범 및 동향

• 국가적 차원의 노력

- 미국 : 연방거래위원회(FTC)에서 '인공지능과 알고리즘 이용에 대한 지침' 발표
- 유럽연합 : 인공지능 윤리 가이드라인 발표
- 중국 : '차세대 인공지능 관리 원칙'이라는 가이드라인 제시
- 일본 : '인공지능 활용 7대 윤리지침' 제정



3. 인공지능과 윤리

5) 인공지능 윤리규범 및 동향

• 국가적 차원의 노력



3. 인공지능과 윤리

5) 인공지능 윤리규범 및 동향

• 기업적 차원의 노력

- 마이크로소프트 : 2017년, 'AI 디자인 원칙'과 'AI 윤리 디자인 가이드'를 제시
2019년, 인공지능 윤리 구현에 필요한 기준을 명시한 '책임 AI 원칙'을 발표
- 구글 : 2018년, 미국 국방부 무인항공기 프로젝트에 인공지능 기술을 제공하는 계약을 체결하면서 'AI 윤리지침'을 발표



네이버 · 카카오 · LG 'AI윤리' 운영 현황

NAVER

- 사람을 위한 AI 개발 · 다양성 존중 · 합리적인 설명과 편리성의 조화 · 안전을 고려한 서비스 설계 · 프라이버시 보호와 정보 보안 등 총 5개 조항으로 구성된 AI 윤리 준칙 발표
- 메일링 그룹 형태의 사내커뮤니케이션 채널 마련
- AI 윤리 준칙의 운영 경과를 담은 프로그레스 리포트 발간 예정

kakao

- 7월 25일 '카카오 공동체 기술윤리 위원회' 출범
- 공동체별 기술윤리를 내재화할 수 있는 틀 마련에 집중
- 향후 유의미한 실천과제 등이 결과로 도출되면 사회에 공유할 예정

LG

- 인간 존중, 공정성, 안정성, 책임성, 투명성 등 5대 핵심 가치를 담은 AI 윤리 원칙 발표
- LG AI연구원에 'AI 윤리 점검 태스크포스 (TF)' 신설
- 그룹 내 AI 관련 주요 윤리 문제를 논의하는 협의체 'AI 윤리 워킹그룹' 출범 예정

정 리 하 기

1. 인공지능 특이점의 쟁점

- 반 인공지능파의 주장 : 사회적 불평등 가속화, 통제 불가능성
- 친 인공지능파의 주장 : 생산의 효율성, 노동으로부터의 해방, 인공지능의 통제 가능성

2. 인공지능 윤리안

- 아실로마 인공지능 원칙 : 인공지능 개발의 목적, 윤리, 가치 등에 대해 개발자가 지켜야 할 23가지 준칙
- 로봇 3원칙 : 로봇이 반드시 따라야 할 3가지 원칙

