

파이썬으로 보는 데이터세상

1강 – 데이터 분석과 Python 소개

1강. 데이터 분석과 Python 소개

데이터 분석과 빅데이터 개념

데이터 분석이란?

- 데이터 분석은 관심의 대상이 되는 연구 목적에 합당한 **자료를 수집하고, 정리 및 분석하여 일반성을 지닌 정보를 도출**하고, 불확실한 상황 하에서 **현명한 의사결정을 하기 위한 이론과 방법**을 체계적으로 다루는 학문
- 또한, 주어진 자료에 근거하여 **자연 현상이나 사회 현상에 대한 과학적인 추론**을 하고, 불확실한 미래를 대비하기 위한 **합리적인 의사결정을 도출**하는 학문

빅데이터(Big Data) 란?

- 위키디피아 : 기존 데이터베이스 관리도구의 데이터 수집, 저장, 관리, 분석 역량을 넘어서는 **대량의 정형 또는 비정형 데이터 세트** 및 이러한 데이터로부터 가치를 추출하고 결과를 분석하는 기술
- 국가전략위원회 : 대용량 데이터를 활용, 분석하여 가치 있는 정보를 추출하고 생성된 지식을 바탕으로 **능동적으로 대응하거나 변화를 예측하기 위한 정보화 기술**
- 삼성경제연구소 : 기존의 관리 및 분석 체계로는 감당할 수 없을 정도의 거대한 데이터 집합으로 이러한 **대규모 데이터와 관계된 기술 및 도구**(수집, 저장, 검색, 공유, 분석, 시각화 등)를 모두 포함하는 개념


빅데이터(Big Data) 란?

- 가트너에서 정의한 빅데이터 5V

기본 3V(Volume, Velocity, Variety)

+ Veracity(정확성)

+ Value(가치)




데이터 vs 정보

- 데이터는 가공되지 않은 일련의 사실들을 의미한다.
- 정보는 의미 있고 유용한 형태로 가공된 데이터를 의미한다.
- 데이터를 가치 있는 정보로 가공하기 위해 데이터마이닝이 핵심적인 역할을 수행할 수 있다.

DIKW 피라미드

- 데이터 ► 정보 ► 지식을 통해 최종적으로 지혜를 얻는 과정의 계층구조



1강. 데이터 분석과 Python 소개

프로그래밍 언어와 파이썬

프로그래밍 언어의 이해


- **프로그래밍 언어(programming language)** : '인간이 원하는 것을 컴퓨터로 실행시키기 위해 사용하는, 컴퓨터가 이해할 수 있는 언어'이다.



[알파고와 이세돌의 바둑 대결(출처: Becoming Human)]

프로그래밍 언어의 이해

- **프로그래밍(programming)** : 프로그래밍 언어를 사용하여 프로그램을 개발하는 것



프로그래밍 언어의 이해

- **프로그래밍 언어를 배우는 이유**

하나의 기술이나 학문으로서 프로그래밍 언어를 배우는 것이 아니라, 논리적인 사고를 훈련하기 위해 프로그래밍 언어를 배워야 한다.

"이 나라의 모든 사람이 프로그램을 배워야 한다. 왜냐하면 프로그램이라는 것은 생각을 어떻게 하는지 가르쳐 주기 때문이다."

- 스티브 잡스

파이썬 소개

- 파이썬의 등장

파이썬(Python)은 귀도 반 로섬(Guido Van Rossum)이 1991년에 개발한 언어로, 처음에는 C 언어 기반으로 개발되었는데 이후 다양한 기능이 개발되어 추가되었다.



[귀도 반 로섬]



[파이썬 로고]

파이썬 소개

- 파이썬의 특징

1. **플랫폼 독립적인 언어** : 어떤 운영체제든 상관없이 사용할 수 있는 언어를 말한다.
2. **인터프리터 언어** : 컴파일러 언어와 달리, 소스코드 자체가 바로 실행되는 특징이 있는 언어이다. 이로 인해 속도는 느리지만, 굉장히 간편하게 사용할 수 있다.
3. **객체 지향 언어** : 해당 프로그램이 해결해야 할 문제의 구성요소를 요소별로 정의한 뒤, 각 요소의 기능(메서드)과 정보(속성)를 정의하여 요소들을 결합하고, 프로그램을 작성하는 방식이다.
4. **동적 타이핑 언어** : 프로그램의 실행 시점에서 각 프로그램 변수의 타입을 결정하는 언어이다.

파이썬 소개

여기서 잠깐! 컴파일러와 인터프리터

구분	컴파일러	인터프리터
작동 방식	소스코드를 기계어로 먼저 번역하고, 해당 플랫폼에 최적화되어 프로그램을 실행함	별도의 번역 과정 없이 소스코드를 실행 시점에 해석하여 컴퓨터가 처리할 수 있도록 함
장점	실행 속도가 빠름	간단히 작성, 메모리가 적게 필요
단점	한 번에 많은 기억 장소가 필요함	실행 속도가 느림
주요 언어	C, 자바(Java), C++, C#	파이썬, 스칼라

[컴파일러와 인터프리터 비교]

파이썬 소개

- 파이썬을 배우는 이유

- 1. 쉽고 간단한 프로그래밍 언어

- 화면에 'Hello World!'라는 텍스트를 출력하는 프로그램을 작성한다고 가정하자. 파이썬과 자바로 코드를 작성하면 아래와 같다.

파이썬

```
print("Hello World!")
```

자바(Java)

```
class HelloWorldApp {  
    public static void main(String[] args) {  
        System.out.println("Hello World!");  
    }  
}
```

파이썬 소개

- 파이썬을 배우는 이유

- 1. 쉽고 간단한 프로그래밍 언어

- 파이썬과 자바로 화면에 1부터 10까지 출력하는 프로그램을 코드로 작성하면
다음처럼 두 언어를 비교할 수 있다.

파이썬

```
for i in range(1, 11):  
    print (i)
```

자바(Java)

```
for (i = 1; i <11; i++ ){  
    System.out.println (i)  
}
```

- 이처럼 파이썬은 프로그래밍을 처음 배우는 초보자도 다른 프로그래밍 언어보다 훨씬 간단하고 이해하기 쉽다는 장점이 있다.

파이썬 소개

- 파이썬을 배우는 이유

2. 다양한 라이브러리 제공

- 파이썬은 다양한 라이브러리를 제공하여 활용 범위가 넓다.
- 개발자들이 만들어 놓은 많은 모듈과 패키지를 쉽게 사용할 수 있다.


라이브러리	설명
pandas	· 고유하게 정의한 Series 및 DataFrame 등의 자료구조를 활용하도록 지원
matplotlib	· 각종 그래프나 차트 등 데이터 시각화 기능 제공
seaborn	· 고급 통계 차트 기능을 제공하며 matplotlib과 상호의존(서로 참조)적
statsmodels	· 추정 및 검정, 회귀분석, 시계열분석 등의 기능을 제공
scikit-learn	· 파이썬의 대표적인 머신러닝용 패키지
tensorflow	· 구글에서 만든 라이브러리로 딥러닝 프로그래밍을 지원하는 패키지

파이썬 소개


- 파이썬을 배우는 이유

- 3. 대중적인 프로그래밍 언어

- 대표적인 컴퓨터 공학 학회지인 「ACMAssociation for Computing Machinery」은 2014년 조사를 통해 미국 39개 대학 중 파이썬을 기초 프로그래밍 언어로 선택한 대학이 가장 많다고 밝혔다.



[미국 39개 대학의 기초 프로그래밍 언어 강의 선택 현황(출처: ACM)]



[파이썬의 성장(출처: Stack Overflow)]

코랩(Colab, 또는 Colaboratory) 이란


코랩

- 구글에서 교육과 과학 연구를 목적으로 개발한 도구
- 어디에서나 스마트폰으로 코랩 노트북에 접속해서 텍스트와 파이썬 코드 작성 및 실행할 수 있다!
- 파이썬 코드 실행은 구글 클라우드 가상 서버에서 이루어진다.
- 별도의 파이썬 라이브러리를 설치하지 않아도 사용할 수 있다.
- 코랩에서 만든 파일은 구글 드라이브에 저장하고 불러올 수 있다.
- 구글 드라이브 문서와 같이 링크만으로 공유 및 협업 가능
- 단, 코드 실행 시 딜레이 존재

코랩 시작하기 : 접속과 로그인

준비물은 브라우저와 구글 계정뿐


- 설치·설정 없이 브라우저만 있으면 바로 시작 (Chrome 권장)
- 주소창에 colab.research.google.com 입력
- 구글 계정으로 로그인 (또는 학교 계정 사용)
- 시작 화면에서 [새 노트] 클릭 → 노트북 생성 완료
- 만든 노트북은 내 구글 드라이브에 자동 저장



새 노트북 만들기과 화면 구성

노트북 화면 한눈에 보기

- 파일 이름(.ipynb)을 클릭해 변경 : 예) 1주차_실습
- 상단 메뉴 : 파일 / 수정 / 보기 / 삽입 / 런타임 / 도구
- [+ 코드], [+ 텍스트] 버튼으로 셀을 추가한다
- 왼쪽 패널 : 목차, 파일, 코드 스니펫
- 오른쪽 위 RAM·디스크 표시는 현재 런타임 연결 상태



코드 셀 실행하기

실행은 재생(▶) 버튼 또는 Shift + Enter

- 코드 셀에 `print('안녕 파이썬')` 을 입력하고 Shift + Enter
- 실행 결과는 셀 바로 아래에 표시된다
- [1], [2] 같은 번호는 실행된 순서를 뜻한다
- Ctrl + Enter : 실행 후 현재 셀 유지 / Alt + Enter : 실행 후 새 셀로 이동
- 실습) $2 + 3 * 4$, $7 / 2$ 의 결과를 직접 확인해 보자



텍스트 셀과 마크다운

코드와 설명을 함께 남기는 학습 노트

- [+ 텍스트] 버튼으로 설명.필기용 셀을 추가한다.
- # 제목1, ## 제목2 : 글자 크기와 구조를 만든다.
- **굵게**, *기울임*, - 목록, 1. 번호 목록
- $y = ax + b$ 처럼 수식도 입력할 수 있다.
- 실습) 오늘 배운 내용을 텍스트 셀에 3줄로 정리하기

장제목

절 제목

항목

어디까지

글쓰기 연습 글을 써보세요.

기울임 글씨 기울임 글씨를 작성했어요.

- 학교
- 교통


1. 첫번째
2. 세번째

$$y = ax + b$$

셀 관리와 실행 순서

모든 셀은 같은 메모리를 공유한다


- 셀 위·아래 이동, 복사, 삭제(휴지통) 버튼 활용
- 앞 셀에서 만든 변수는 뒤 셀에서 계속 사용할 수 있다
- 앞 셀을 실행하지 않으면 NameError 오류가 발생한다
- 순서가 헷갈리면 [런타임] → [모두 실행]
- 노트북은 위에서 아래로 읽히도록 정리하는 습관을 들이자



런타임 관리

코드를 실행해 주는 구글 클라우드 컴퓨터


- [런타임] → [세션 다시 시작] : 변수와 메모리를 초기화
- [런타임] → [런타임 유형 변경] : CPU / GPU / TPU 선택
- 약 90분간 조작이 없으면 연결이 끊어진다
- 최대 연속 사용 시간은 약 12시간 (무료 기준)
- 연결이 끊기면 코드는 남지만 변수는 사라진다 → 다시 실행



파일 다루기와 구글 드라이브 연결

데이터는 드라이브에 두는 것이 안전하다

- 왼쪽 [파일] 패널에 끌어 놓기 = 임시 업로드 (세션 종료 시 삭제)
- 드라이브 연결 : `from google.colab import drive`
- `drive.mount('/content/drive')` 실행 후 권한 승인
- 연결된 경로 : `/content/drive/MyDrive/` 아래 내 파일들
- 예) `pd.read_csv('/content/drive/MyDrive/data.csv')`



라이브러리 사용하기


대부분은 이미 설치되어 있다

- pandas, numpy, matplotlib 등은 기본으로 제공된다
- 사용 전에 `import pandas as pd` 처럼 불러오기
- 없는 라이브러리는 `!pip install 라이브러리명` 으로 설치
- 맨 앞의 `!` 는 리눅스 명령 실행을 뜻한다 (`!ls`, `!pwd`)
- 설치한 라이브러리는 세션이 끊기면 다시 설치해야 한다

저장 · 공유 · 과제 제출

링크 하나로 제출까지 끝난다

- 작업 내용은 드라이브의 'Colab Notebooks' 폴더에 자동 저장
- [파일] → [사본 저장] / [다운로드 .ipynb]
- [파일] → [인쇄] 로 PDF 형태 보고서 만들기
- 오른쪽 위 [공유] 버튼 → 보기 · 댓글 · 편집 권한 선택
- 과제 제출은 공유 링크 또는 .ipynb 파일 업로드



미션과 자주하는 질문

5분 미션으로 마무리하기

1. 미션 1) 노트북 이름을 '학번_이름_1주차'로 바꾸기
2. 미션 2) 텍스트 셀에 자기소개, 코드 셀에 print로 출력하기
3. 미션 3) 공유 링크를 LMS 게시판에 제출하기
4. 자주 하는 실수 : 셀 실행 안 함, 따옴표 짝 안 맞음, 파일 경로 오류
5. 다음 주 예고 : 변수와 자료형, 그리고 첫 데이터 다루기